

Programa de Residência em TIC 16

Projeto Sistema para Previsibilidade de Geração de Energia Elétrica Utilizando Imagens de Painéis Solares

Relatório Técnico

1. Introdução

Este trabalho aborda a aplicação de modelos de visão computacional para detecção e segmentação de painéis solares em imagens aéreas, um problema que exige tanto a correta localização dos objetos quanto a delimitação precisa de suas áreas. Nesse contexto, foram utilizados dois tipos de abordagens: o modelo YOLO e a arquitetura U-NET com *encoder* baseado em *Resnet*. Todos os algoritmos empregados nos processos de treinamento e inferência foram implementados na linguagem de programação Python.

2. Fundamentação Teórica dos Modelos

O modelo YOLO (*You Only Look Once*) é amplamente reconhecido por sua eficiência em tarefas de detecção em tempo real. Sua principal característica é realizar todas as predições em uma única passagem pela rede neural, o que reduz significativamente o custo computacional. O uso de pesos pré-treinados permite a aplicação de *transfer learning*, contribuindo para melhor desempenho mesmo com conjuntos de dados limitados.

Por outro lado, a arquitetura U-NET com Resnet segue uma abordagem clássica de segmentação semântica. Ela possui uma estrutura composta por um *encoder*, responsável pela extração de características, e um *decoder*, que reconstrói a imagem segmentada. A utilização de Resnet melhora a capacidade de extração de características profundas. Esse tipo de modelo tende a apresentar alta precisão na delimitação dos objetos, sendo especialmente eficaz na segmentação pixel a pixel.

3. Especificações de Hardware

A máquina oferecida durante a residência dispõe das seguintes especificações:

- Processador: Intel Core i7 1355U (13ª Geração)
- Memória RAM: 16 GB
- Gráficos: Intel Iris Xe Graphics (Integrada)

Inicialmente, os treinamentos foram realizados na máquina da residência. Contudo, o tempo de treinamento durou em média 36 horas e, por isso, fez-se a

mudança para a plataforma Kaggle que oferece 30 horas semanais gratuitas para treinamentos com possibilidade de desfrutar de uma placa de vídeo GPU T4x2.

4. Treinamento dos modelos

Para obter os modelos para segmentação dos painéis solares, seguiu-se os passos elencados:

- a) Corte e conversão para .png do conjunto de 14 imagens enviadas pelo EQT LAB;
- b) Anotação dos painéis solares nas imagens no Roboflow;
- c) Criação de um novo Dataset; e
- d) Treinamento e validação usando modelos pré-treinados.

As 14 imagens originais apresentavam resolução de 8192×5346 pixels, sendo necessária sua subdivisão em blocos de 800×800 pixels, o que resultou em um conjunto de 1.030 imagens. Inicialmente, as imagens no formato .tiff foram convertidas para o formato .png. Em seguida, realizou-se o processo de anotação por meio da plataforma Roboflow, responsável pela geração das *labels* utilizadas no treinamento dos modelos de segmentação. Do total de imagens obtidas após o recorte, 269 continham painéis solares, enquanto as demais correspondiam a regiões sem a presença desse objeto.

No desenvolvimento do primeiro modelo, foi utilizado um conjunto de dados composto principalmente por imagens de painéis solares isolados e usinas fotovoltaicas de grande porte, contendo poucas imagens de sistemas fotovoltaicos instalados em telhados residenciais. Como o objetivo deste trabalho é a segmentação semântica de painéis solares, em sua maioria, em coberturas residenciais, foi necessário criar um conjunto de dados mais representativo desse cenário.

Para ampliar o conjunto de imagens, utilizou-se a ferramenta *Explore* da plataforma Roboflow, realizando buscas com termos em inglês, como “solar”, “solar panel”, “aerial solar panel” e “aerial”, para localizar bases de dados públicas relacionadas ao tema. Além disso, foi realizada uma seleção das imagens do conjunto solar_segmentation, mantendo apenas aquelas mais adequadas.

Com o objetivo de reduzir a ocorrência de falsos positivos, também foram adicionadas imagens de cenários urbanos e de elementos que poderiam ser confundidos com painéis solares, como ruas, telhados sem painéis e piscinas. Dessa forma, foi obtido um novo conjunto de dados mais equilibrado, composto principalmente por imagens aéreas verticais de áreas urbanas. O novo dataset contém 1665 imagens e 1665 *labels*, das quais 1337 são de treino e 288 de validação.

A etapa final consistiu no refinamento dos modelos YOLO e U-NET previamente treinados, com o objetivo de melhorar o desempenho na segmentação dos painéis solares utilizando o novo conjunto de dados. Para o treinamento da arquitetura U-NET, foi necessário converter as anotações do conjunto de dados em máscaras de segmentação, uma vez que esse modelo utiliza máscaras binárias como referência durante o processo de aprendizado.

4.1. YOLO

A versão YOLO11m-seg utilizada neste trabalho incorpora a segmentação por instância, permitindo não apenas identificar a localização dos painéis solares, mas também gerar máscaras que representam suas áreas com maior detalhamento. Esse modelo é previamente treinado em um conjunto de dados (Dataset COCO) e contém os pesos e vieses que representam as características de qualquer conjunto de dados em que foi treinado.

A Tabela 1 apresenta os parâmetros empregados durante o treinamento a fim de obter o arquivo *best.pt* que contém as informações de pesos (*weights*) e vieses (*biases*) de cada camada convolucional para segmentação dos painéis. Nesse procedimento foram adicionadas técnicas de aumento de dados para criar amostras que melhoram a otimização e generalização do modelo.

Parâmetro	Valor	Finalidade Técnica
<i>imgsz</i>	640x640	Resolução de redimensionamento das imagens de entrada
<i>epochs</i>	150	Quantidade máxima de iterações sobre o conjunto de dados
<i>batch</i>	16	Número de imagens processadas por vez na GPU
<i>patience</i>	50	Limite de épocas sem melhora antes da interrupção (<i>Early Stopping</i>)
<i>Amp</i>	<i>True</i>	Uso de Precisão Mista Automática para acelerar o treino
<i>pretrained</i>	<i>True</i>	Uso de pesos pré-treinados para <i>Transfer Learning</i>
<i>optimizer</i>	auto	Seleção automática do otimizador (SGD ou AdamW)
<i>workers</i>	2	Número de núcleos para carregamento de dados
<i>Variação de matiz (HSV Hue – hsv h)</i>	0,01	Introduz pequenas variações na tonalidade das imagens, aumentando a robustez do modelo a mudanças de cor.
<i>Variação de saturação (HSV Saturation – hsv s)</i>	0,30	Simula diferentes níveis de saturação, tornando o modelo menos sensível às condições de iluminação e câmera.
<i>Variação de brilho (HSV Value – hsv v)</i>	0,20	Simula alterações de luminosidade, permitindo maior robustez a diferentes condições de iluminação.
<i>Degrees</i>	$\pm 15^\circ$	Gera imagens rotacionadas para aumentar a invariância do modelo em relação à orientação dos painéis solares.

<i>Translate</i>	0,03	Desloca a imagem horizontal e verticalmente, tornando o modelo mais robusto a pequenas variações de posicionamento.
<i>Scale</i>	0,05	Simula pequenas variações no tamanho dos objetos presentes na imagem.
<i>Flip Left-Right</i>	0,50	Realiza espelhamento horizontal em metade das imagens, aumentando a diversidade do conjunto de treinamento.
<i>Mosaic</i>	0,40	Combina quatro imagens em uma única amostra, aumentando a diversidade espacial e melhorando a capacidade de generalização do modelo.
<i>Close Mosaic</i>	Últimas 20 épocas	Desativa a augmentação Mosaic nas últimas épocas para que o modelo seja refinado utilizando imagens mais próximas das condições reais.
<i>checkpoint</i>	/kaggle/working/best.pt	Arquivo com o melhor modelo durante todo o treinamento

Tabela 1 - Parâmetros de Treino com o YOLO11m-seg.

4.2. U-NET

A arquitetura U-Net permite utilizar a ResNet34 como encoder, aproveitando os pesos pré-treinados no conjunto de dados ImageNet para a extração de características das imagens. A U-Net realiza segmentação semântica, na qual cada pixel da imagem é classificado em uma determinada classe. Neste trabalho, os pixels são classificados como pertencentes à classe painel solar ou fundo.

Nesse treinamento foi aplicado o método de aumento de dados por meio de alterações em características das imagens, como rotação, variação de cores, entre outros (Veja Tabela 2). Esse procedimento aumenta a quantidade de dados para treino e, por conseguinte, melhora a robustez do modelo, reduz o *overfitting* e melhora a generalização para cenários do mundo real.

Parâmetro	Valor	Finalidade Técnica
Número de <i>workers</i>	2	Define a quantidade de processos paralelos utilizados para o carregamento e pré-processamento das imagens.
Épocas máximas	60	Define o número máximo de ciclos de treinamento do modelo.
Resolução das imagens	512 × 512 pixels	Padroniza o tamanho das imagens de entrada, reduzindo o custo computacional e mantendo os detalhes necessários para a segmentação.
Batch size	8	Define a quantidade de imagens processadas a cada atualização dos pesos da rede.
Tarefa	Segmentação semântica binária (1 classe)	Classifica cada pixel da imagem como painel solar ou fundo .
Dropout no decoder	0,2	Reduz o risco de sobreajuste (<i>overfitting</i>) ao desativar

		aleatoriamente neurônios durante o treinamento.
Saída do modelo	Logits brutos (sigmoid aplicado na função de perda)	Produz valores não normalizados, permitindo maior estabilidade no cálculo da função de perda durante o treinamento.
Precisão mista (AMP)	Ativada (Float16 + Float32)	Reduz o consumo de memória e acelera o treinamento mantendo a estabilidade numérica.
Gradient clipping	max_norm = 1,0	Limita a magnitude dos gradientes para evitar instabilidades durante o treinamento.
Parada antecipada (Patience)	12 épocas sem melhoria no Val IoU	Interrompe o treinamento quando não há melhora no IoU de validação, reduzindo o risco de sobreajuste.
Redimensionamento	512 × 512 pixels	Padroniza o tamanho das imagens de entrada, reduzindo o custo computacional e garantindo uniformidade durante o treinamento e a validação.
Flip horizontal	p = 0,5	Realiza espelhamento horizontal em 50% das imagens, aumentando a diversidade do conjunto de treinamento.
Flip vertical	p = 0,5	Realiza espelhamento vertical em 50% das imagens, tornando o modelo mais robusto a diferentes orientações.
Rotação de 90°	p = 0,5	Gera imagens rotacionadas em 90°, aumentando a capacidade de generalização do modelo.
Transformação afim	Translação ±3%, escala de 90–110%, rotação ±20°, p = 0,5	Simula pequenas variações de posição, tamanho e orientação dos objetos presentes na imagem.
Hue, Saturation e Value (HSV)	Hue ±10, saturação ±35, valor ±25, p = 0,5	Simula variações de cor e iluminação, tornando o modelo menos sensível às condições de captura das imagens.
ColorJitter	Brilho, contraste e saturação = 0,25; hue = 0,05; p = 0,4	Introduz pequenas alterações de brilho, contraste, saturação e matiz para aumentar a robustez do modelo.
CLAHE	Clip limit = 2,5; grade 8 × 8; p = 0,35	Melhora o contraste local da imagem, destacando detalhes importantes para a segmentação.
RandomShadow	1–2 sombras; região de interesse completa; p = 0,25	Simula sombras naturais presentes nas cenas aéreas, tornando o modelo mais robusto a esse tipo de interferência.
Gaussian Blur	Kernel 3–5; p = 0,2	Simula imagens levemente desfocadas, reduzindo a

		sensibilidade do modelo a variações de foco.
GaussNoise	Desvio padrão de 0,01–0,04; $p = 0,2$	Adiciona ruído gaussiano para aumentar a robustez a ruídos presentes nas imagens.
CoarseDropout (oclusões)	1–4 regiões; tamanho de 8–32 pixels; $p = 0,2$	Simula oclusões parciais dos objetos, aumentando a capacidade do modelo de identificar painéis parcialmente ocultos.
Normalização	Média (0,485; 0,456; 0,406) e desvio padrão (0,229; 0,224; 0,225)	Padroniza os valores dos pixels conforme o ImageNet, facilitando o treinamento e o uso da ResNet34 pré-treinada.
<i>checkpoint</i>	/kaggle/working/melhor_modelo.pth	Salva o modelo com melhor IoU de validação

Tabela 2 - Parâmetros de Treino com o U-NET encoder Resnet 34.

5. Teste de inferência

Os testes com os melhores modelos gerados nos treinamentos foram feitos no conjunto de 52 imagens (com dimensões de 3840 x 2160) disponibilizadas pela EQT Lab. Essas imagens tratam de regiões em anos diferentes da cidade de São Luís. O procedimento de teste seguiu as seguintes etapas:

- Levantamento manual da quantidade de painéis nas imagens;
- Aplicação do algoritmo de inferência (YOLO e U-NET) sobre as imagens para gerar máscaras das segmentações;
- Comparação entre o quantitativo de painéis obtidos na etapa a) e resultado obtido no item b), bem como os falsos positivos; e
- Cálculo das métricas de análise.

5.1 Resultados YOLO

O algoritmo de inferência baseado no modelo YOLO inicia com o carregamento da rede previamente treinada e da imagem a ser analisada. Antes da inferência, as imagens são submetidas a um pré-processamento para garantir compatibilidade com o modelo, sendo convertidas para o padrão RGB quando necessário. O algoritmo foi desenvolvido para processar diferentes formatos de entrada (.jpg, .jpeg, .png, .tif e .tiff), proporcionando maior flexibilidade na utilização de imagens provenientes de diferentes fontes.

Devido às elevadas dimensões das imagens analisadas, foi utilizada a técnica de *tiling*, que consiste na subdivisão da imagem original em blocos menores de 640×640 pixels com sobreposição de 300 pixels entre blocos adjacentes. Após a etapa de

particionamento, cada tile é processado individualmente pelo modelo YOLO, utilizando os pesos do arquivo *best.pt*, obtido durante o treinamento descrito na Seção 4.1. Durante a inferência, o parâmetro *imgsz* foi configurado para 1024×1024 pixels, fazendo com que cada tile fosse redimensionado internamente pelo modelo antes do processamento. Para cada bloco analisado, o modelo retorna máscaras de segmentação, caixas delimitadoras (*bounding boxes*) e os respectivos níveis de confiança associados às detecções. Foi adotado um limiar mínimo de confiança de 0,3 para considerar uma detecção válida e um limiar de *Intersection over Union* (IoU) de 0,6.

As máscaras obtidas são projetadas de volta para suas posições originais, formando uma máscara global da imagem. Em seguida, aplica-se o algoritmo *Non-Maximum Suppression* (NMS) para remover detecções duplicadas resultantes da sobreposição entre os blocos.

Por fim, as regiões segmentadas são destacadas na imagem original por meio de máscaras semitransparentes e contornos, permitindo a visualização dos painéis identificados. Nesse contexto, foram geradas 52 imagens com os painéis segmentados pelo modelo YOLO.

Para avaliar quantitativamente o desempenho do modelo, foram utilizadas as métricas **Precisão**, **Recall** e **F1-Score**, calculadas a partir da comparação entre as segmentações produzidas pelo algoritmo e a anotação manual das imagens de referência. Essas métricas permitem avaliar, respectivamente, a capacidade do modelo em evitar falsas detecções, identificar corretamente os painéis existentes e equilibrar ambas as características em uma única medida de desempenho. As equações I, II e III apresentam o cálculo dessas métricas:

$$\text{I. } \textit{Precisão} = \frac{VP}{VP + FP}$$

$$\text{II. } \textit{Recall} = \frac{VP}{VP + FN}$$

$$\text{III. } \textit{F1 Score} = 2 \cdot \frac{\textit{Precisão} \cdot \textit{Recall}}{\textit{Precisão} + \textit{Recall}}$$

onde,

- **VP (Verdadeiro Positivo):** painel solar existente na imagem que foi corretamente detectado pelo algoritmo.
- **Falso Positivo (FP):** região identificada pelo algoritmo como painel solar, mas que não corresponde a um painel na imagem de referência.
- **Falso Negativo (FN):** painel solar presente na imagem de referência que não foi detectado pelo algoritmo.

A Tabela 3 apresenta os resultados obtidos pelo modelo YOLO11m-seg, considerando apenas as segmentações cuja confiança foi superior a 80%. No total, foram avaliadas 52 imagens contendo 3.035 painéis solares anotados manualmente. O modelo identificou corretamente 2.713 painéis (verdadeiros positivos), registrando 333 falsos positivos e 322 falsos negativos, o que resultou em precisão de 89,07%, recall de 89,39% e F1-Score de 89,23%.

Yolo 11m-seg							
Segmentações com mais de 80%							
Nome da Imagem	Painéis	VP	FP	FN	Precisão	Recall	F1-Score
capture_r01c21_2023-05	51	49	2	2	96,08%	96,08%	96,08%
capture_r01c21_2024-05	69	67	4	2	94,37%	97,10%	95,71%
capture_r01c21_2025-04	104	95	1	9	98,96%	91,35%	95,00%
capture_r01c22_2023-05	22	19	-	3	100,00%	86,36%	92,68%
capture_r01c22_2024-05	26	26	2	-	92,86%	100,00%	96,30%
capture_r01c22_2025-04	39	37	-	2	100,00%	94,87%	97,37%
capture_r02c09_2023-05	56	53	9	3	85,48%	94,64%	89,83%
capture_r02c09_2024-05	57	56	-	1	100,00%	98,25%	99,12%
capture_r02c09_2025-04	52	51	4	1	92,73%	98,08%	95,33%
capture_r02c10_2023-05	95	73	13	22	84,88%	76,84%	80,66%
capture_r02c10_2024-05	93	88	30	5	74,58%	94,62%	83,41%
capture_r02c10_2025-04	101	84	11	17	88,42%	83,17%	85,71%
capture_r02c21_2023-05	6	5	5	1	50,00%	83,33%	62,50%
capture_r02c21_2024-05	9	9	2	-	81,82%	100,00%	90,00%
capture_r02c21_2025-04	9	8	5	1	61,54%	88,89%	72,73%
capture_r02c22_2023-05	4	4	3	-	57,14%	100,00%	72,73%
capture_r02c22_2024-05	7	7	5	-	58,33%	100,00%	73,68%
capture_r02c22_2025-04	10	10	4	-	71,43%	100,00%	83,33%
capture_r03c09_2023-05	55	42	6	13	87,50%	76,36%	81,55%

capture_r03c09_2024-05	51	50	4	1	92,59%	98,04%	95,24%
capture_r03c09_2025-04	57	57	3	-	95,00%	100,00%	97,44%
capture_r03c10_2023-05	25	25	14	-	64,10%	100,00%	78,13%
capture_r03c10_2024-05	23	23	11	-	67,65%	100,00%	80,70%
capture_r03c10_2025-04	41	41	16	-	71,93%	100,00%	83,67%
capture_r05c15_2023-05	58	39	2	19	95,12%	67,24%	78,79%
capture_r05c15_2024-05	47	47	4	-	92,16%	100,00%	95,92%
capture_r05c15_2025-04	54	46	3	8	93,88%	85,19%	89,32%
capture_r05c16_2023-05	157	129	8	28	94,16%	82,17%	87,76%
capture_r05c16_2024-05	155	143	18	12	88,82%	92,26%	90,51%
capture_r05c16_2025-04	169	154	27	15	85,08%	91,12%	88,00%
capture_r06c15_2023-05	26	22	6	4	78,57%	84,62%	81,48%
capture_r06c15_2024-05	33	29	4	4	87,88%	87,88%	87,88%
capture_r06c15_2025-04	39	32	7	7	82,05%	82,05%	82,05%
capture_r06c16_2023-05	104	104	3	-	97,20%	100,00%	98,58%
capture_r06c16_2024-05	111	109	2	2	98,20%	98,20%	98,20%
capture_r06c16_2025-04	155	151	3	4	98,05%	97,42%	97,73%
capture_r06c18_2022-07	29	28	2	1	93,33%	96,55%	94,92%
capture_r06c18_2023-05	84	56	28	28	66,67%	66,67%	66,67%
capture_r06c18_2025-04	48	8	7	40	53,33%	16,67%	25,40%
capture_r06c19_2022-07	45	43	8	2	84,31%	95,56%	89,58%
capture_r06c19_2023-05	112	109	5	3	95,61%	97,32%	96,46%
capture_r06c19_2025-04	194	193	1	1	99,48%	99,48%	99,48%
capture_r06c20_2023-05	66	66	6	-	91,67%	100,00%	95,65%
capture_r06c20_2024-05	71	71	7	-	91,03%	100,00%	95,30%
capture_r06c20_2025-04	115	115	6	-	95,04%	100,00%	97,46%

capture_r06c21_2023-05	8	8	-	-	100,00%	100,00%	100,00%
capture_r06c21_2024-05	11	11		-	100,00%	100,00%	100,00%
capture_r06c21_2025-04	11	11		-	100,00%	100,00%	100,00%
capture_r06c22_2023-05	2	2	2	-	50,00%	100,00%	66,67%
capture_r06c22_2024-05	2	2	11	-	15,38%	100,00%	26,67%
capture_r06c22_2025-04	2	2	3	-	40,00%	100,00%	57,14%
capture_r07c18_2025-04	65	4	6	61	40,00%	6,15%	10,67%
TOTAL	3.035	2.713	333	322	89,07%	89,39%	89,23%

Tabela 3 - Resultado YOLO 11m-seg

De forma geral, os resultados demonstram que o modelo apresentou elevado desempenho na detecção e segmentação dos painéis solares, mantendo equilíbrio entre precisão e recall. Em grande parte das imagens, o F1-Score permaneceu acima de 90%, evidenciando boa capacidade de generalização mesmo em imagens adquiridas em diferentes anos e cenários urbanos. Observa-se que diversas imagens apresentaram desempenho próximo ao ideal. Destacam-se, por exemplo, as imagens *capture_r06c21* (anos de 2023, 2024 e 2025), nas quais o modelo obteve precisão, recall e F1-Score iguais a 100%, bem como as imagens *capture_r06c19_2025-04* e *capture_r02c09_2024-05*, cujos F1-Scores foram superiores a 99%. Esses resultados indicam que, em cenários com características semelhantes aos presentes no conjunto de treinamento, o modelo é capaz de identificar praticamente todos os painéis solares com reduzida ocorrência de erros.

Entretanto, alguns cenários apresentaram desempenho inferior. O caso mais crítico ocorreu na imagem *capture_r07c18_2025-04*, em que foram identificados apenas 4 dos 65 painéis existentes, resultando em recall de apenas 6,15% e F1-Score de 10,67%. Também se destacam as imagens *capture_r06c18_2025-04*, *capture_r06c22_2024-05* e as imagens da região *r02c21/r02c22*, que apresentaram aumento significativo de falsos positivos ou falsos negativos, reduzindo o desempenho das métricas.

A análise individual das imagens sugere que essas reduções de desempenho estão associadas principalmente a mudanças nas características visuais das cenas, como diferenças de resolução, iluminação, tamanho aparente dos painéis, presença de sombras e alterações no padrão construtivo das edificações. Em situações nas quais os painéis

possuem dimensões muito reduzidas ou apresentam baixo contraste em relação ao telhado, observou-se maior dificuldade do modelo em realizar a segmentação correta.

Apesar dessas exceções, os resultados indicam que o refinamento do YOLO11m-seg utilizando esse conjunto de dados proporcionou um modelo robusto para a segmentação de painéis solares em imagens aéreas, apresentando bom equilíbrio entre precisão e capacidade de detecção, características importantes para aplicações práticas de monitoramento e inventário de sistemas fotovoltaicos. Após a análise do desempenho do modelo YOLO11m-seg, a próxima seção apresenta os resultados obtidos com a arquitetura U-NET. A comparação entre as métricas obtidas pelos dois modelos permite avaliar suas respectivas capacidades de segmentação dos painéis solares, bem como identificar suas vantagens e limitações em diferentes cenários de aplicação.

5.2. Resultados U-NET

O algoritmo de inferência utilizado pelo modelo U-NET para a segmentação de painéis solares inicia com o carregamento do modelo previamente treinado e da imagem TIFF que será processada. Em seguida, caso a imagem possua múltiplos canais espectrais, são selecionados os três primeiros canais para compor uma imagem no padrão RGB, garantindo a compatibilidade com a arquitetura da rede neural.

Como as imagens podem ser muito grandes para serem processadas de uma única vez, o algoritmo divide a imagem em blocos de 512×512 pixels, com uma sobreposição de 300 pixels entre blocos adjacentes. Essa estratégia permite processar imagens extensas sem exceder os limites de memória e reduz problemas de segmentação nas bordas dos blocos.

Cada tile é submetido ao modelo U-Net, que produz um mapa de probabilidades indicando a chance de cada pixel pertencer à classe de interesse (painel solar). Nas regiões sobrepostas, as probabilidades geradas por diferentes tiles são acumuladas e posteriormente combinadas por meio da média das predições. Esse procedimento suaviza transições entre blocos e melhora a consistência da segmentação final.

Após o processamento completo da imagem, é gerada uma matriz de probabilidades global. Em seguida, aplica-se um limiar de confiança de 0,30, convertendo o mapa probabilístico em uma máscara binária, na qual os pixels classificados como painéis solares recebem valor 1 e os demais recebem valor 0.

Por fim, os resultados são salvos em disco em dois formatos: imagem *overlay*, contendo a segmentação sobreposta à imagem original e máscara binária, contendo apenas as regiões classificadas como painéis solares.

A Tabela 4 apresenta os resultados obtidos pelo modelo U-NET com encoder ResNet34, considerando apenas as segmentações com nível de confiança superior a 80%. No conjunto de teste, composto por 52 imagens contendo 3.035 painéis solares, o modelo identificou corretamente 2.658 painéis (verdadeiros positivos), registrando 191 falsos positivos e 377 falsos negativos. Esses resultados correspondem a uma precisão de 93,30%, recall de 87,58% e F1-Score de 90,35%.

Unet+Resnet DataSet Novo							
Segmentações com mais de 80%							
Nome da Imagem	Painéis	VP	FP	FN	Precisão	Recall	F1-Score
capture_r01c21_2023-05	51	45	5	6	90,00%	88,24%	89,11%
capture_r01c21_2024-05	69	63	2	6	96,92%	91,30%	94,03%
capture_r01c21_2025-04	104	92	6	12	93,88%	88,46%	91,09%
capture_r01c22_2023-05	22	17	3	5	85,00%	77,27%	80,95%
capture_r01c22_2024-05	26	26	1	-	96,30%	100,00%	98,11%
capture_r01c22_2025-04	39	37	1	2	97,37%	94,87%	96,10%
capture_r02c09_2023-05	56	53	6	3	89,83%	94,64%	92,17%
capture_r02c09_2024-05	57	56	4	1	93,33%	98,25%	95,73%
capture_r02c09_2025-04	52	52	-	-	100,00%	100,00%	100,00%

capture_r02c10_2023-05	95	73	10	22	87,95%	76,84%	82,02%
capture_r02c10_2024-05	93	82	13	11	86,32%	88,17%	87,23%
capture_r02c10_2025-04	101	67	10	34	87,01%	66,34%	75,28%
capture_r02c21_2023-05	6	4	-	2	100,00%	66,67%	80,00%
capture_r02c21_2024-05	9	8	1	1	88,89%	88,89%	88,89%
capture_r02c21_2025-04	9	7	1	2	87,50%	77,78%	82,35%
capture_r02c22_2023-05	4	4	2	-	66,67%	100,00%	80,00%
capture_r02c22_2024-05	7	7	-	-	100,00%	100,00%	100,00%
capture_r02c22_2025-04	10	10	-	-	100,00%	100,00%	100,00%
capture_r03c09_2023-05	55	54	3	1	94,74%	98,18%	96,43%
capture_r03c09_2024-05	51	50	-	1	100,00%	98,04%	99,01%
capture_r03c09_2025-04	57	54	2	3	96,43%	94,74%	95,58%
capture_r03c10_2023-05	25	25	8	-	75,76%	100,00%	86,21%
capture_r03c10_2024-05	23	23	2	-	92,00%	100,00%	95,83%
capture_r03c10_2025-04	41	40	10	1	80,00%	97,56%	87,91%

capture_r05c15_2023-05	58	51	-	9	100,00%	85,00%	91,89%
capture_r05c15_2024-05	47	38	-	9	100,00%	80,85%	89,41%
capture_r05c15_2025-04	54	48	1	6	97,96%	88,89%	93,20%
capture_r05c16_2023-05	157	131	3	26	97,76%	83,44%	90,03%
capture_r05c16_2024-05	155	145	5	10	96,67%	93,55%	95,08%
capture_r05c16_2025-04	169	151	12	18	92,64%	89,35%	90,96%
capture_r06c15_2023-05	26	23	8	3	74,19%	88,46%	80,70%
capture_r06c15_2024-05	33	29	3	4	90,63%	87,88%	89,23%
capture_r06c15_2025-04	39	28	3	11	90,32%	71,79%	80,00%
capture_r06c16_2023-05	104	79	8	25	90,80%	75,96%	82,72%
capture_r06c16_2024-05	111	94	11	17	89,52%	84,68%	87,04%
capture_r06c16_2025-04	155	148	12	7	92,50%	95,48%	93,97%
capture_r06c18_2022-07	29	21	2	8	91,30%	72,41%	80,77%
capture_r06c18_2023-05	84	40	5	44	88,89%	47,62%	62,02%
capture_r06c18_2025-04	48	32	4	16	88,89%	66,67%	76,19%

capture_r06c19_2022-07	45	43	4	2	91,49%	95,56%	93,48%
capture_r06c19_2023-05	112	104	3	8	97,20%	92,86%	94,98%
capture_r06c19_2025-04	194	188	3	6	98,43%	96,91%	97,66%
capture_r06c20_2023-05	66	57	1	9	98,28%	86,36%	91,94%
capture_r06c20_2024-05	71	62	3	9	95,38%	87,32%	91,18%
capture_r06c20_2025-04	115	111	1	4	99,11%	96,52%	97,80%
capture_r06c21_2023-05	8	8		-	100,00%	100,00%	100,00%
capture_r06c21_2024-05	11	9		2	100,00%	81,82%	90,00%
capture_r06c21_2025-04	11	11		-	100,00%	100,00%	100,00%
capture_r06c22_2023-05	2	2	1	-	66,67%	100,00%	80,00%
capture_r06c22_2024-05	2	2	1	-	66,67%	100,00%	80,00%
capture_r06c22_2025-04	2	2	2	-	50,00%	100,00%	66,67%
capture_r07c18_2025-04	65	52	5	13	91,23%	80,00%	85,25%
TOTAL	3.035	2.658	191	377	93,30%	87,58%	90,35%

Tabela 4 - Resultado Unet + Resnet

De maneira geral, o modelo apresentou elevada precisão na maioria das imagens analisadas, indicando baixa ocorrência de falsas detecções. Em diversos cenários, a precisão foi igual ou superior a 95%, alcançando inclusive 100% em algumas imagens, como *capture_r02c09_2025-04*, *capture_r02c22_2024-05*, *capture_r02c22_2025-04*, *capture_r06c21_2023-05* e *capture_r06c21_2025-04*. Esses resultados demonstram que, quando o modelo realiza uma detecção, ela tende a corresponder efetivamente a um painel solar.

Em relação ao recall, embora o desempenho tenha sido elevado em grande parte do conjunto de teste, observam-se alguns cenários em que o modelo deixou de identificar uma quantidade significativa de painéis. Os casos mais representativos ocorreram nas imagens *capture_r06c18_2023-05*, com recall de 47,62%, e *capture_r06c18_2025-04*, com 66,67%, evidenciando aumento da quantidade de falsos negativos. Situação semelhante foi observada em *capture_r02c10_2025-04* e *capture_r06c15_2025-04*, nas quais parte dos painéis existentes não foi segmentada pelo modelo.

De forma semelhante ao observado no modelo YOLO, essas reduções de desempenho estão associadas às características específicas das imagens, como variações de iluminação, presença de sombras, diferenças de resolução, tamanho aparente dos painéis e complexidade dos telhados. Nessas situações, o modelo apresentou comportamento mais conservador, priorizando detecções de maior confiabilidade em detrimento da identificação de todos os painéis presentes na imagem.

De maneira geral, os resultados demonstram que o U-NET com encoder ResNet34 apresentou desempenho consistente na segmentação dos painéis solares, produzindo poucas falsas detecções e elevada precisão. Entretanto, em alguns cenários, observou-se redução da capacidade de identificar todos os objetos de interesse, aspecto que será analisado de forma comparativa com o modelo YOLO na Seção 5.3.

5.3 Métricas Gerais dos Modelos

A Tabela 5 apresenta as métricas gerais obtidas pelos modelos YOLO11m-seg e U-NET com encoder ResNet34 a partir da análise do conjunto de imagens utilizado nos testes de inferência.

Os resultados demonstram que ambos os modelos apresentaram bom desempenho na segmentação de painéis solares, alcançando valores superiores a 89% em todas as métricas avaliadas. Em relação à precisão, o modelo U-NET obteve 93,30%, enquanto o YOLO alcançou 89,07%, indicando que o U-NET apresentou menor incidência de falsos positivos e maior confiabilidade nas detecções realizadas.

Quanto ao recall, os modelos apresentaram desempenhos bastante próximos. O YOLO atingiu 89,39%, enquanto o U-NET obteve 87,58%, evidenciando que ambos foram capazes de identificar a maior parte dos painéis solares presentes nas imagens, com uma ligeira vantagem para o YOLO na capacidade de detecção.

Ao considerar simultaneamente precisão e recall por meio do F1-Score, observa-se que o U-NET apresentou o melhor desempenho global, alcançando 90,35%, enquanto o YOLO obteve 89,23%. Essa diferença, embora pequena, indica que o U-NET apresentou um equilíbrio ligeiramente superior entre a redução de falsas detecções e a identificação dos painéis existentes.

De forma geral, os resultados demonstram que as duas arquiteturas apresentaram desempenho consistente e adequado para a tarefa de segmentação de painéis solares em imagens aéreas. O YOLO destacou-se por sua ligeira vantagem no recall, enquanto o U-NET apresentou maior precisão e o melhor F1-Score. Dessa forma, ambas as abordagens mostram-se viáveis para a aplicação proposta, sendo que o U-NET apresentou desempenho global discretamente superior no conjunto de testes utilizado neste trabalho.

Métrica	YOLO	U-NET
Precisão	89,07%	93,30%
Recall	89,39%	87,58%
F1-Score	89,23%	90,35%

Tabela 5 - Métricas Gerais dos Modelos

6. Teste de avaliação

O teste avaliativo consistiu na realização de uma análise automática utilizando as ferramentas disponibilizadas pelos frameworks Ultralytics e PyTorch, com o objetivo de obter as métricas de desempenho relacionadas à detecção e à segmentação dos painéis solares. Para essa avaliação, foram selecionadas 10 imagens do conjunto de teste de inferência (Tabela 6), as quais foram subdivididas em blocos de 800×800 pixels, sem sobreposição (overlap). Esse processo resultou na geração de 270 imagens, que posteriormente foram anotadas manualmente na plataforma Roboflow, formando o conjunto de referência (ground truth) utilizado na avaliação quantitativa dos modelos.

Nome das Imagens
capture r01c21 2023-05
capture r01c21 2024-05

capture_r06c18_2025-04
capture_r06c19_2022-07
capture_r06c20_2023-05
capture_r06c20_2024-05
capture_r06c20_2025-04
capture_r06c22_2023-05
capture_r06c22_2024-05
capture_r06c22_2025-04

Tabela 6 – Imagens escolhidas para Teste de Avaliação.

5.1. YOLO

O framework YOLO disponibiliza o parâmetro “split=“test””, que possibilita a avaliação do modelo em um conjunto de teste independente, calculando automaticamente as métricas de desempenho da tarefa de segmentação. As métricas obtidas por meio desse procedimento são apresentadas na Tabela 7.


Métricas Detecção		Métricas Segmentação	
Precision	79,35 %	Precision	80,92 %
Recall	74,74 %	Recall	73,71 %
F1-Score	76,98 %	F1-Score	77,15 %
mAP50	79,28 %	mAP50	78,95 %
mAP50-95	49,10 %	mAP50-95	51,50 %

Tabela 7 – Métricas geradas pelo YOLO.

Na etapa de detecção, o modelo alcançou 79,35% de precisão e 74,74% de recall, resultando em um F1-Score de 76,98%, indicando um bom equilíbrio entre a capacidade de identificar corretamente os painéis e a redução de falsos positivos. O mAP@50 de 79,28% evidencia que o modelo apresenta elevada capacidade de localizar os objetos quando considerado um limiar de IoU de 50%. Já o mAP@50–95 de 49,10% é inferior por utilizar critérios progressivamente mais rigorosos de sobreposição, refletindo a maior dificuldade em obter delimitações extremamente precisas.

Na tarefa de segmentação, os resultados foram ligeiramente superiores em termos de precisão (80,92%) e F1-Score (77,15%), enquanto o recall (73,71%) permaneceu próximo ao observado na detecção. Além disso, o mAP@50–95 de 51,50% superou o da detecção, sugerindo que o modelo foi capaz de produzir máscaras com melhor aderência ao contorno real dos painéis quando avaliadas em diferentes limiares de IoU.

A matriz de confusão mostra que o YOLO11m-seg identificou corretamente 603 painéis solares, evidenciando boa capacidade de detecção. Entretanto, ocorreram 185 falsos positivos e 173 falsos negativos, indicando que algumas regiões de fundo foram classificadas como painéis e que parte dos painéis presentes não foi detectada. De forma geral, os resultados demonstram um desempenho satisfatório do modelo, com potencial para aprimorar a redução de falsas detecções e aumentar a taxa de identificação dos objetos de interesse.



5.2. U-NET

O teste avaliativo da U-Net consistiu na aplicação do modelo treinado sobre o conjunto de teste. As predições geradas foram comparadas às anotações reais para mensurar o desempenho da segmentação por meio de métricas quantitativas, permitindo avaliar a capacidade de generalização e a precisão do modelo em dados não utilizados durante o treinamento. A tabela X mostra as métricas obtidas durante os testes.

Métricas de segmentação	
IoU	62,17%
Dice	76,68%
Precision	91,73 %
Recall	65,87 %
F1-Score	76,68%
Acurácia	99,73%

Tabela 8 – Métricas geradas pela U-NET.

O modelo U-Net, aplicado em uma tarefa de segmentação semântica (classificação pixel a pixel entre painel solar e fundo), alcançou um IoU de 62,17% e

um Dice de 76,68%, indicando sobreposição moderada a boa entre as máscaras preditas e as máscaras reais. A precisão de 91,73% mostra que a maioria dos pixels classificados como painel de fato correspondem a painéis, com baixa taxa de falsos positivos. Já o recall de 65,87% revela que uma parcela significativa dos pixels de painéis reais não foi capturada pelo modelo, o que também explica o F1-Score de 76,68%, coerente com o Dice (ambas as métricas são matematicamente equivalentes em segmentação binária). A acurácia de 99,73%, embora alta, é pouco informativa nesse contexto devido ao forte desbalanceamento entre pixels de fundo e de painel na imagem. Em conjunto, os resultados indicam que o modelo é conservador, priorizando confiabilidade das detecções (precisão) em detrimento da cobertura completa dos painéis existentes (recall).

A Figura 2 mostra que o modelo UNet identificou corretamente 629.111 pixels/instâncias de painéis solares (verdadeiros positivos) e classificou corretamente 141.605.738 áreas sem painel (verdadeiros negativos). Ele gerou 56.738 falsos positivos, ou seja, apontou painel onde não havia, mas esse número é pequeno frente ao total, resultando em precisão alta (91,7%). O ponto de atenção é 326.013 pixel de falsos negativos, isto é, painéis reais que o modelo deixou de detectar, o que reduz o recall para 65,9%.

	Predito positivo	Predito negativo
Real positivo	VERDADEIRO POSITIVO 629.111	FALSO NEGATIVO 326.013
Real negativo	FALSO POSITIVO 56.738	VERDADEIRO NEGATIVO 141.605.738

7. Conclusão

Neste trabalho foram desenvolvidos e avaliados dois modelos de visão computacional para a segmentação de painéis solares em imagens aéreas: o YOLO11m-seg e o U-NET com encoder ResNet34. Para isso, foi utilizado um conjunto de dados contendo imagens de painéis solares em áreas urbanas, utilizado para o refinamento (*fine tuning*) dos modelos e posterior avaliação em um conjunto independente de imagens fornecido pela EQT Lab.

Os resultados obtidos demonstraram que ambas as arquiteturas foram capazes de realizar a segmentação automática dos painéis solares com bom desempenho, evidenciando o potencial das técnicas de deep learning para aplicações de inventário e monitoramento de sistemas fotovoltaicos. A análise comparativa mostrou que os modelos apresentam características complementares: o YOLO11m-seg destacou-se pela ligeira vantagem na capacidade de detecção dos painéis presentes nas imagens, enquanto o U-NET apresentou maior precisão e obteve o melhor desempenho global quando consideradas conjuntamente as métricas de avaliação. Entretanto, as diferenças observadas entre as arquiteturas foram pequenas, indicando que ambas constituem alternativas viáveis para a aplicação proposta.

Além da comparação entre os modelos, este trabalho estabeleceu um fluxo completo para segmentação de painéis solares em imagens aéreas, contemplando as etapas de preparação do conjunto de dados, treinamento, inferência e avaliação quantitativa dos resultados. Os experimentos realizados evidenciaram que a qualidade e a diversidade do conjunto de treinamento exercem influência direta sobre a capacidade de generalização dos modelos, reforçando a importância da utilização de bases de dados representativas para aplicações em ambientes reais.

Embora os resultados obtidos tenham sido satisfatórios, ainda existem oportunidades de aprimoramento. Como trabalhos futuros, é recomendado ampliar e diversificar o conjunto de treinamento, incorporando imagens obtidas sob diferentes condições de iluminação, resolução espacial, ângulos de aquisição, tipos de cobertura e características urbanas. Também podem ser investigadas estratégias de aumento de dados (*data augmentation*), otimização de hiperparâmetros e arquiteturas mais recentes de segmentação, visando aumentar a robustez e a capacidade de generalização dos modelos.

Por fim, conclui-se que os objetivos propostos neste trabalho foram alcançados, uma vez que foi possível desenvolver, treinar e avaliar modelos capazes de identificar automaticamente painéis solares em imagens aéreas com bom desempenho. Os resultados obtidos demonstram a viabilidade da aplicação de técnicas de visão computacional como ferramenta de apoio ao inventário e ao monitoramento de sistemas fotovoltaicos, contribuindo para o planejamento da expansão da geração distribuída e para o desenvolvimento de soluções voltadas ao setor energético.

8. Referências

LECUN, Yann; BENGIO, Yoshua; HINTON, Geoffrey. Deep learning. *Nature*, London, v. 521, n. 7553, p. 436-444, 2015.

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. *Deep Learning*. Cambridge: MIT Press, 2016.

HOWARD, Jeremy; GUGGER, Sylvain. *Deep Learning for Coders with Fastai and PyTorch*. Sebastopol: O'Reilly Media, 2020.

SIMONYAN, Karen; ZISSERMAN, Andrew. Very deep convolutional networks for large-scale image recognition. 2015. Disponível em: <https://arxiv.org/abs/1409.1556>. Acesso em: 11 jun. 2026.

OPENCV. *OpenCV Documentation*. Disponível em: <https://docs.opencv.org>. Acesso em: 11 jun. 2026.

PASZKE, Adam *et al.* PyTorch: An Imperative Style, High-Performance Deep Learning Library. In: *Advances in Neural Information Processing Systems 32 (NeurIPS 2019)*. Red Hook: Curran Associates, 2019. p. 8024-8035.

ULTRALYTICS. *COCO Dataset – COCO Pretrained Models*. 2025. Disponível em: <https://docs.ultralytics.com/datasets/detect/coco/#coco-pretrained-models>. Acesso em: 11 jun. 2026.

ULTRALYTICS. *Transfer Learning*. 2026. Disponível em: <https://www.ultralytics.com/glossary/transfer-learning>. Acesso em: 11 jun. 2026.

ULTRALYTICS. *YOLO11 Documentation*. 2025. Disponível em: <https://docs.ultralytics.com/models/yolo11/>. Acesso em: 11 jun. 2026.

ULTRALYTICS. *Ultralytics Documentation*. Disponível em: <https://docs.ultralytics.com>. Acesso em: 11 jun. 2026.

ZHOU, Zongwei *et al.* UNet++: A nested U-Net architecture for medical image segmentation. In: *DEEP LEARNING IN MEDICAL IMAGE ANALYSIS AND MULTIMODAL LEARNING FOR CLINICAL DECISION SUPPORT*, 2018. *Proceedings [...]* Cham: Springer, 2018. p. 3-11.

RONNEBERGER, Olaf; FISCHER, Philipp; BROX, Thomas. *U-Net: Convolutional Networks for Biomedical Image Segmentation*. In: *INTERNATIONAL CONFERENCE ON MEDICAL IMAGE COMPUTING AND COMPUTER-ASSISTED INTERVENTION (MICCAI)*, 18., 2015, Munich. *Proceedings [...]* Cham: Springer, 2015. p. 234-241.

SHORTEN, Connor; KHOSHGOFTAAR, Taghi M. A survey on image data augmentation for deep learning. *Journal of Big Data*, London, v. 6, art. 60, 2019.